UNIVERSIDADE CATÓLICA DO SALVADOR
CURSO DE BACHARELADO EM ENGENHARIA DE SOFTWARE

LUCAS ALVES MATOS SAMPAIO GASPARI
WALTER QUEIROZ ROCHA
GUILHERME FERREIRA SAMPAIO

UNIFICAÇÃO, TRATAMENTO, MODELAGEM, ARMAZENAMENTO E INFRAESTRUTURA DOS DADOS

Tema: Auditoria de Viés Étnico-Gênero em Fomento à Pesquisa Científica

Salvador
2026

LUCAS ALVES MATOS SAMPAIO GASPARI
WALTER QUEIROZ ROCHA
GUILHERME FERREIRA SAMPAIO

UNIFICAÇÃO, TRATAMENTO, MODELAGEM, ARMAZENAMENTO E INFRAESTRUTURA DOS DADOS

Tema: Auditoria de Viés Étnico-Gênero em Fomento à Pesquisa Científica

Trabalho apresentado à disciplina Big Data e Analytics do curso de Bacharelado em Engenharia de Software da Universidade Católica do Salvador, como entrega técnica da fase 2.

Salvador
2026

1 INTRODUÇÃO

Esta fase preparou a base definida na etapa anterior. Os dados de 2019 a 2024 foram tratados, unificados a partir de duas fontes do CNPq e armazenados em um PostgreSQL no Aiven, com a infraestrutura descrita em Terraform. Todo o código, a base tratada e a documentação estão no repositório `https://github.com/WalterQueirozRocha/Trabalho-big-data`, e o `README.md` traz o passo a passo de execução.

Durante a preparação, verificou-se que o CSV exportado do painel não traz sexo nem raça ou cor, que são as dimensões centrais da auditoria. Por isso, o CSV foi unificado com um extrato agregado do próprio painel, que contém essas informações.

2 BASE DE DADOS TRATADA

2.1 Origem e versão original

As duas fontes vêm do Painel de Demanda e Atendimento do CNPq, que utiliza dados da Plataforma Integrada Carlos Chagas. O recorte é feito pelo ano da chamada (`ano_chamada`), de 2019 a 2024, e pelas linhas de bolsas no país, bolsas no exterior e apoio a projetos de pesquisa.

Quadro 1 – Origem e versão original dos dados

Fonte	**Conteúdo**	**Versão original utilizada**
CSV de dados abertos (`Base_CNPq_Demanda_Atendimento_2019_2024.csv`)	Uma linha por processo: chamada, modalidade, área, instituição, região, valores e situação. Não tem sexo nem raça ou cor	100.693.334 bytes, 142.222 linhas e 39 colunas, separador “;”. SHA-256: `18d9dfddd734ffca2db1310a6e3eaad1cf2a7c2d8af57918a53e525f9da09120`
Relatório Power BI do painel	Mesmo cadastro, com sexo e raça ou cor, em totais por grupo	Extrato com 57.656 combinações e 13 colunas, salvo sem tratamento em `data/raw`

Fonte: Elaboração própria (2026).

2.2 Versão resultante

A versão tratada está em `data/processed` e é exatamente a que foi carregada no banco. Executar o tratamento de novo sobre o mesmo CSV gera arquivos idênticos.

Quadro 2 – Versão resultante após o tratamento

Arquivo	Conteúdo	Linhas
`fato_atendimento_grupo.csv`	Painel agregado por ano, sexo, raça ou cor, grande área, linha de fomento, modalidade e região	9.173
`fato_atendimento_csv.csv`	CSV agregado pelas mesmas dimensões, sem sexo e raça ou cor	1.397
`processo_tratado.csv`	Um processo por linha, já tratado, sem sexo e raça ou cor	139.761
`dim_*.csv`	Grande área, linha de fomento, modalidade e região padronizadas	11, 3, 13 e 7
`log_tratamento.csv`	Quantidade de linhas afetadas por cada regra	44

Fonte: Elaboração própria (2026).

3 PROCESSO DE TRATAMENTO DOS DADOS

O processo foi desenvolvido em Python 3.14, com pandas para o tratamento, requests para a extração e pg8000 para a carga. São três scripts executados em sequência, que reconstroem a base inteira a partir das fontes.

Quadro 3 – Scripts do processo

Script	Função
`extrair_painel.py`	Consulta o painel ano a ano e salva o extrato agregado por sexo e raça ou cor
`tratar.py`	Filtra, padroniza, remove duplicados e reenvios, corrige valores, agrega e gera as dimensões comuns
`carregar.py`	Recria as tabelas, carrega os arquivos tratados com `COPY` e libera leitura ao usuário de análise

Fonte: Elaboração própria (2026).

As etapas de tratamento foram:

- leitura do CSV em blocos, com todos os campos como texto;
- padronização de grafias de cidade, UF, instituição e categorias, comparando por uma chave sem acento, caixa e pontuação;
- validação da UF contra a lista oficial e correção da região a partir da UF;
- dedução da modalidade vazia pelas outras edições da mesma chamada e correção da grande área pela classificação predominante da área;
- recorte de 2019 a 2024 e seleção das linhas de bolsas e auxílios à pesquisa;
- remoção de duplicados exatos e de reenvios da mesma proposta;
- conversão de tipos e correção de valores zerados, com vírgula deslocada ou implausíveis;
- agregação das duas fontes pelas mesmas dimensões.

Quadro 4 – Quantidade de linhas por etapa

Etapa	Painel	CSV
Linhas lidas	57.656	142.222
Sem números de processo repetidos	–	142.222
Recorte de 2019 a 2024	57.656	142.222
Somente bolsas e auxílios	53.340	139.999
Sem duplicados exatos (14) e reenvios (224)	–	139.761
Após agregação	9.173	1.397

Fonte: Elaboração própria (2026).

O CSV já vinha restrito ao período, então o tratamento atuou mais nas colunas e nos valores do que no número de linhas: 33.985 grafias de cidade e 48.897 de nome de UF foram unificadas, 14.136 modalidades vazias foram deduzidas e 6.250 siglas de instituição foram padronizadas. A tabela de processos ficou com 14 das 39 colunas, e o arquivo de 100 MB caiu para 16,4 MB. Foram criados 45 testes automatizados em Python e 4 testes do Terraform, todos aprovados.

4 DECISÕES TÉCNICAS E JUSTIFICATIVAS

Quadro 5 – Decisões técnicas

Decisão	Justificativa
Sexo e raça ou cor extraídos somente de forma agregada	Raça ou cor é dado pessoal sensível (LGPD, art. 5º, II) e a auditoria compara grupos, sem precisar de registros individuais
Unificação das fontes por dimensões comuns	Ano, grande área, linha de fomento, modalidade e região permitem comparar e reconciliar as duas bases
Uso de `nme_chamada_macro` como linha de fomento	A coluna `nme_linha_fomento` tinha valor inválido em 85,9% das linhas
Somente bolsas no país, bolsas no exterior e apoio a projetos	São as linhas definidas na Etapa 1; a chamada ARC, eventos e prêmios ficam de fora
Leitura com parser CSV e campos como texto	Títulos e palavras-chave contêm ponto e vírgula, o que deslocaria colunas
Grafias unificadas pela forma acentuada mais frequente	Junta variações como “SAO PAULO” e “São Paulo” sem juntar nomes diferentes
Erros de UF corrigidos só contra a lista oficial	Evita “corrigir” um valor certo para outro valor errado da própria base
Reenvios removidos, mantendo o atendido ou o último	A mesma proposta submetida duas vezes inflaria a demanda
Valor zero tratado como nulo; vírgula deslocada corrigida; implausível como nulo	Ninguém pede R$ 0, e um valor mil vezes acima da mediana distorceria os totais

(continua)

(continuação)

Decisão	Justificativa
Valor atendido maior que o demandado mantido	Pode ocorrer de forma legítima; excluir alteraria os totais
"Não desejo declarar" e ausentes como "Não informado"	Mantidos como categoria própria, sem redistribuir entre grupos
Taxa de atendimento calculada no banco	Coluna gerada garante que a taxa sempre corresponda às quantidades
Diferença entre grupos calculada em view	Usa homens brancos, o maior grupo, como referência, sem alterar os dados
Sem amostragem	Grupos pequenos ficariam instáveis
Carga em uma transação, com certificado validado	Uma falha não deixa o banco pela metade e a conexão é protegida

Fonte: Elaboração própria (2026).

5 BASE ARMAZENADA EM BANCO DE DADOS

Os dados estão em um PostgreSQL 17 no Aiven, em um modelo dimensional: duas tabelas fato que compartilham quatro dimensões (constelação de fatos) e uma tabela de processos. O modelo foi escolhido porque a auditoria consulta medidas recortadas por categorias, e as dimensões compartilhadas garantem que as duas fontes usem os mesmos nomes. Cada tabela tem quatro chaves estrangeiras, uma para cada dimensão, em relacionamentos de um para muitos. Numa carga de teste o banco ocupou 32 MB, cerca de 5% da meta de 650 MB da Etapa 1.

Figura 1 – Modelo dimensional: tabelas à esquerda, dimensões à direita

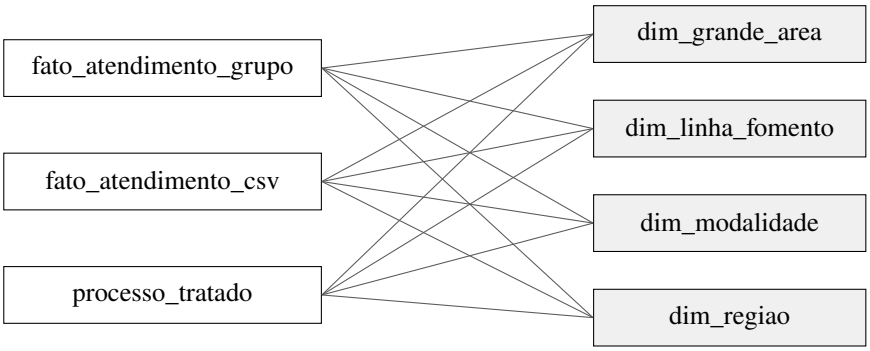

Cada linha é uma chave estrangeira, em relação de um (dimensão) para muitos (tabela).

Fonte: Elaboração própria (2026).

Quadro 6 – Tabelas, campos e quantidade armazenada

Tabela	Principais campos e tipos	Registros
`fato_atendimento_grupo`	ano SMALLINT; sexo VARCHAR(20); raça ou cor VARCHAR(30); 4 chaves SMALLINT; quantidades INTEGER; valores NUMERIC(16,2); taxa NUMERIC(7,4) gerada	9.173
`fato_atendimento_csv`	Mesmos campos, sem sexo, raça ou cor e taxa	1.397
`processo_tratado`	nu_processo VARCHAR(20) chave primária; ano; 4 chaves; UF CHAR(2); cidade, sigla, instituição e país; atendido BOOLEAN; valores NUMERIC(16,2)	139.761
`dim_*`	id SMALLSERIAL; nome VARCHAR único	11, 3, 13 e 7
`vw_diferenca_grupo` (view)	Taxa por ano, área, sexo e raça ou cor e diferença para o grupo de referência	740
`vw_reconciliacao_fontes` (view)	Totais do painel e do CSV por ano, área e linha de fomento	137

Fonte: Elaboração própria (2026).

6 INFRAESTRUTURA

A infraestrutura está descrita como código em `infra/terraform`, com o provider oficial do Aiven. O plano gratuito (`free-1-1gb`: 1 CPU, 1 GB de RAM e 1 GB de disco) foi escolhido porque não tem prazo nem exige cartão, o que mantém o custo do projeto em zero. Como esse plano não existe na América do Sul, a região padrão é `aws-us-east-1`.

Quadro 7 – Recursos provisionados pelo Terraform

Recurso	Função
`aiven_pg.banco`	Serviço PostgreSQL 17, com filtro de IP e etiquetas do projeto
`aiven_pg_database.fomento`	Banco `fomento_cnpq`, separado do banco padrão
`aiven_pg_user.leitura`	Usuário `analise_leitura`, com senha gerada pelo Aiven, para as próximas fases
`local_sensitive_file.env` e `.ca`	Grava o `.env` (permissão 0600) e o certificado `ca.pem` que o ETL usa

Fonte: Elaboração própria (2026).

A região foi colocada em `ignore_changes` porque o Aiven pode mover serviços gratuitos de região; sem isso, o Terraform tentaria migrar o banco de volta. Os testes do Terraform usam providers simulados, então verificam o plano sem precisar de conta. Um workflow do GitHub Actions roda os testes Python, valida o Terraform e procura segredos a cada envio ao repositório.

7 SEGURANÇA DAS INFORMAÇÕES

Nenhuma credencial está no repositório. O token da API do Aiven fica apenas na variável de ambiente `AIVEN_TOKEN` de quem executa o Terraform, lida sem eco no terminal. As senhas do banco não são escolhidas nem digitadas por ninguém: o Aiven as gera e o Terraform as grava no `.env` local, que o script de carga lê.

Quadro 8 – Tratamento das credenciais

Medida	**Como foi aplicada**
Arquivos sensíveis fora do Git	`.gitignore` cobre `.env`, certificados, `*.tfstate` e `*.tfvars`; o repositório só tem modelos sem valores
Saídas sensíveis	URLs de conexão marcadas como `sensitive` no Terraform, sem aparecer no `plan`
Conexão protegida	TLS com verificação do certificado e do nome do servidor pelo `ca.pem` do projeto
Menor privilégio	Usuário de análise só com `SELECT`; testes confirmam que ele não altera dados nem cria tabelas
Varredura de segredos	gitleaks no histórico completo; a única ocorrência é a chave pública do painel Power BI, publicada pelo próprio CNPq
Plano de resposta	Revogar o token, recriar o usuário com `-replace` ou redefinir a senha no console

Fonte: Elaboração própria (2026).

8 LIMITAÇÕES

O painel cobre mais processos que o CSV: 184.794 propostas contra 139.761 no período. A diferença fica registrada na view de reconciliação, sem ajuste artificial. A auditoria usa o painel, que é a fonte com sexo e raça ou cor. Além disso, a consulta ao painel depende de uma interface não documentada; por isso o extrato original fica salvo no repositório. No plano gratuito não há alta disponibilidade, e o serviço pode ser desligado por falta de uso.

REFERÊNCIAS

AIVEN. **Aiven for PostgreSQL free tier**. 2026. Disponível em: `https://aiven.io/docs/products/postgresql/concepts/pg-free-tier`. Acesso em: 20 set. 2026.

AIVEN. **Aiven Provider for Terraform**. 2026. Disponível em: `https://registry.terraform.io/providers/aiven/aiven/latest/docs`. Acesso em: 31 out. 2026.

BRASIL. **Lei nº 13.709, de 14 de agosto de 2018**. Lei Geral de Proteção de Dados Pessoais. Brasília, DF, 2018.

CNPQ. **Painel de Demanda e Atendimento**. Brasília, DF, 2026. Disponível em: https://www.gov.br/cnpq/pt-br/acesso-a-informacao/dados-abertos/paineis-de-dados/painel-de-demanda-e-atendimento. Acesso em: 8 out. 2026.

SAMPAIO, G. F.; GASPARI, L. A. M. S.; ROCHA, W. Q. **Levantamento de parâmetros e tipagem de dados**. Salvador: UCSAL, 2026. Trabalho da disciplina Big Data e Analytics.

HASHICORP. **Terraform tests**. 2026. Disponível em: https://developer.hashicorp.com/terraform/language/tests. Acesso em: 31 out. 2026.

KIMBALL, R.; ROSS, M. **The data warehouse toolkit**: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

UCSAL. **Guia de orientação do projeto prático**: Big Data. Salvador: Universidade Católica do Salvador, 2026. Material da disciplina.